



datarisk

DECISION AS A SERVICE

Case Técnico

Cientista de Dados Júnior

Contexto do Desafio

Você é um cientista de dados na Datarisk, uma empresa de consultoria especializada em soluções de dados e inteligência de crédito. Atuamos com grandes instituições financeiras, desenvolvendo modelos preditivos, sistemas de apoio à decisão e estratégias baseadas em dados.

Neste desafio, você foi alocado em um projeto que envolve o acompanhamento de transações financeiras realizadas por clientes ao longo do tempo. O objetivo do projeto é desenvolver um modelo que ajude a prever situações de **inadimplência por atraso no pagamento**, com base no histórico de comportamento e nas características dos clientes.

A equipe do projeto está construindo um sistema que roda periodicamente, recebendo novas informações dos clientes mês a mês. O seu papel é desenvolver uma solução capaz de identificar, com antecedência, quais clientes têm maior probabilidade de **não pagar uma determinada cobrança no prazo esperado**.

Essa informação será utilizada para definir ações proativas de cobrança, tentando reduzir o índice de inadimplência da empresa.

Objetivo do Case

O objetivo deste case é que você desenvolva um modelo preditivo capaz de estimar a **probabilidade de inadimplência** de cobranças mensais feitas aos clientes.

As previsões devem ser geradas para os registros presentes na base **base_pagamentos_teste.csv**, que representa o conjunto de cobranças mais recentes da empresa. Para cada linha dessa base, o modelo deve estimar a **probabilidade de inadimplência**.

Neste projeto, a inadimplência é definida da seguinte forma:

Um pagamento é considerado inadimplente se for realizado com **5 dias ou mais de atraso** em relação à data de vencimento.

Para isso, você terá à disposição:

- O histórico de pagamentos anteriores realizados pelos clientes
- Informações cadastrais e de perfil
- Dados mensais de acompanhamento dos clientes, como renda do mês anterior e número de funcionários

⚠ As previsões devem conter **apenas a probabilidade** de inadimplência (valores entre 0 e 1). **Não é necessário gerar uma classificação binária.**

⚠ A forma como você trata os dados, estrutura a solução e interpreta o problema **será levada em consideração** na avaliação.

Bases de Dados

Você terá acesso a quatro bases de dados com informações sobre os clientes, o comportamento mensal e os registros de pagamentos. Essas bases foram extraídas de um sistema de cobrança e representam um cenário realista de operação. As tabelas se relacionam principalmente por duas chaves:

- **ID_CLIENTE**: identifica cada cliente de forma única
- **SAFRA_REF**: representa o período de referência da cobrança

A estrutura esperada de cada base é a seguinte:

base_cadastral.csv: reúne informações cadastrais dos clientes, como data de cadastro, porte da empresa, CEP e domínio do e-mail. Cada linha representa um cliente único (**ID_CLIENTE**).

base_info.csv: traz dados mensais relacionados ao cliente, como renda do mês anterior e número de funcionários. Cada linha representa um cliente em um determinado mês (**ID_CLIENTE**, **SAFRA_REF**).

base_pagamentos_desenvolvimento.csv: contém o histórico de cobranças e pagamentos já realizados. Cada linha representa uma cobrança mensal para um cliente (**ID_CLIENTE**, **SAFRA_REF**), com as datas de vencimento e pagamento disponíveis para construção da variável target.

base_pagamentos_teste.csv: contém as cobranças mais recentes, para as quais o modelo deve prever a probabilidade de inadimplência. Cada linha representa uma cobrança mensal, sem a informação de pagamento.

⚠ O **dicionário de dados completo** e a **tabela de relacionamento** entre as bases estão disponíveis na seção **Anexos**, ao final deste documento.

Entregáveis

Sua entrega deve conter todos os elementos necessários para **reproduzir a solução** e **avaliar as previsões geradas** para os casos presentes na base **base_pagamentos_teste.csv**.

Os seguintes itens são esperados:

1. Arquivo com as previsões

Um arquivo **.csv** chamado **submissao_case.csv**, contendo exatamente as seguintes colunas:

- **ID_CLIENTE**
- **SAFRA_REF**
- **PROBABILIDADE_INADIMPLENCIA**

2. Código-fonte reprodutível

Você pode entregar sua solução em um dos formatos: um notebook único (**.ipynb**) ou vários arquivos Python(**.py**). O mais importante é que **seu código possa ser executado do início ao fim, gerando o mesmo resultado enviado**.

Para garantir isso, é recomendado incluir:

- Um arquivo **requirements.txt** ou similar com as bibliotecas utilizadas e suas versões.
- A versão da linguagem de programação utilizada (ex: Python 3.10).
- Qualquer outro arquivo necessário para a execução da solução.

 O **requirements.txt** é um arquivo de texto onde você lista as versões das bibliotecas utilizadas na sua solução. Isso ajuda a evitar erros de compatibilidade entre ambientes diferentes.

 Se as versões das bibliotecas não forem informadas, a execução da sua solução poderá depender do ambiente do avaliador, o que pode gerar erros.

Apesar de não ser obrigatório, é altamente recomendado que você inclua uma explicação sobre as decisões tomadas na sua solução. Isso pode ser feito no próprio notebook ou em um documento separado.

Formato da Submissão

A entrega final deve ser feita por **e-mail**, por meio de um **único** arquivo **.zip**, contendo **todos os arquivos necessários para executar a sua solução**, conforme descrito na seção anterior.

⚠ A avaliação será realizada de forma **anônima**, para evitar qualquer viés. Por isso, **não inclua seu nome, LinkedIn, GitHub ou qualquer outra informação pessoal** nos arquivos, nomes de pastas ou dentro do código.

⚠ **Não envie nenhuma base de dados**, nem mesmo arquivos intermediários gerados durante o processamento. Seu código deve ser capaz de **reproduzir todos os dados necessários**, a partir das bases fornecidas.

⚠ Você pode, se quiser, publicar sua solução em um repositório pessoal no GitHub (por exemplo, como parte do seu portfólio). Mas a **submissão oficial deve ser feita por e-mail**, no formato solicitado acima, respeitando as orientações de anonimidade.

Critérios de Avaliação

Diversos aspectos serão considerados durante a avaliação da sua solução. A seguir, listamos alguns pontos que servem como **direcionamento geral**:

Construção da variável target

Será necessário construir corretamente a variável de inadimplência com base na regra fornecida (pagamentos com atraso igual ou superior a 5 dias). Preste bastante atenção nesse ponto, pois é essencial para o sucesso da solução.

Exploração dos dados

Seja curioso e criativo. Explore bem os dados disponíveis e aproveite ao máximo as informações presentes nas bases. Esse tipo de iniciativa será muito bem visto na avaliação.

Organização e clareza

Soluções bem estruturadas, com código limpo, organizado e comentado facilitam a compreensão. Incluir explicações sobre as decisões tomadas também contribui positivamente para sua avaliação.

Escolha de técnicas

Você pode utilizar qualquer abordagem ou algoritmo que julgar adequado, mas recomendamos que use técnicas com as quais você se sinta confortável — especialmente caso seja necessário explicar sua solução em uma etapa futura.

⚠ Se você for selecionado para a próxima etapa, poderá ser convidado a apresentar sua solução. Por isso, certifique-se de que suas decisões estejam bem justificadas e fáceis de explicar.

Observações Finais

- **Recomendamos fortemente** que você utilize **Python** na sua solução, já que é a linguagem mais comum no nosso dia a dia. No entanto, **soluções em outras linguagens também serão aceitas**, desde que cumpram todos os requisitos de reprodutibilidade e clareza mencionados neste documento.
- Pense na sua entrega como uma simulação real de projeto. **Construa a solução como se estivesse apresentando para um cliente**: explique suas decisões, mostre por que seguiu determinado caminho e justifique por que sua proposta faz sentido.
- Você pode (e deve!) pesquisar materiais, tutoriais ou exemplos para te apoiar na construção da solução. **Se possível, mencione as fontes que consultou**. Isso será muito valorizado.
- Lembre-se: soluções simples, bem estruturadas e bem explicadas costumam se destacar muito mais do que abordagens complexas sem uma base sólida.

⚠ As **descrições completas das variáveis** e a **tabela de relacionamento entre as bases** estão na próxima seção, em **Anexos**. Consulte sempre que necessário.


Em caso de dúvidas, sinta-se à vontade para entrar em contato conosco.

Desejamos boa sorte no desafio!

Anexos

A) Tabela de Relacionamento

Abaixo está a tabela de relacionamento entre as tabelas fornecidas. Recomendamos que você explore essas relações para montar sua base final de modelagem de forma estruturada.



B) Dicionário de Dados

base_cadastral.csv

Base contendo informações cadastrais dos clientes. Cada cliente deve ter apenas uma data de cadastro e seus dados não mudam ao longo do tempo.

ID_CLIENTE: Identificador único do cliente.

DATA_CADASTRO: Data da realização do cadastro no sistema.

DDD: Número do DDD do telefone do cliente.

FLAG_PF: Indica se o cliente é uma pessoa física ('X') ou jurídica ('NaN').

SEGMENTO_INDUSTRIAL: Indica a qual segmento da indústria pertence o cliente.

DOMINIO_EMAIL: Indica o domínio(ou provedor) do email utilizado para o cadastro.

PORTE: Indica o porte (tamanho) da empresa.

CEP_2_DIG: Indica os dois primeiros números do CEP do endereço cadastrado.

base_info.csv

Base com informações adicionais dos clientes. Essa base é atualizada mensalmente, então cada cliente aparecerá apenas uma vez em cada mês de referência. Ou seja, o identificador único da base consiste na combinação do **ID_CLIENTE** e da **SAFRA_REF**.

ID_CLIENTE: Identificador único do cliente

SAFRA_REF: Mês de referência da amostra

RENDA_MES_ANTERIOR: Renda ou faturamento declarado pelo cliente no fim do mês anterior

NO_FUNCIONARIOS: Número de funcionários reportado pelo cliente no fim do mês anterior

base_pagamentos_desenvolvimento.csv

Base com informações históricas sobre transações (empréstimos) já realizadas pelos clientes. Cada cliente pode ter uma ou mais transações no mesmo período de tempo. Essa base deve ser utilizada no desenvolvimento do modelo, pois contém os dados de pagamento.

ID_CLIENTE: Identificador único do cliente

SAFRA_REF: Mês de referência da amostra

DATA_EMISSAO_DOCUMENTO: Data da emissão da nota de crédito

DATA_VENCIMENTO: Data limite para pagamento do empréstimo

VALOR_A_PAGAR: Valor da nota de crédito

TAXA: Taxa de juros cobrada no empréstimo

DATA_PAGAMENTO: Data em que o cliente realizou o pagamento da nota

base_pagamentos_teste.csv

Base com as transações mais recentes, que ainda não foram pagas.

Seu papel será prever a probabilidade de inadimplência para essas transações. A estrutura é a mesma da base de desenvolvimento, **porém sem a coluna DATA_PAGAMENTO.**

ID_CLIENTE: Identificador único do cliente

SAFRA_REF: Mês de referência da amostra

DATA_EMISSAO_DOCUMENTO: Data da emissão da nota de crédito

DATA_VENCIMENTO: Data limite para pagamento do empréstimo

VALOR_A_PAGAR: Valor da nota de crédito

TAXA: Taxa de juros cobrada no empréstimo